DOCUMENTAZIONE UFFICIALE & GUIDA OPERATIVA END-TO-END

Sentiment Analysis & Social Listening Hub

Piattaforma Enterprise di Social Listening, Deep Learning NLP e Data Governance per l'Industria Cinematografica e dei Media

Progetto:	Sentiment Analysis & Social Listening Hub
Architettura Dati:	Medallion Architecture (Bronze, Silver, Gold Layers)
Database & Storage:	MongoDB 6.0 con JSON Schema Validation e Indici Idempotenti
Modello NLP:	RoBERTa EN + XLM-RoBERTa multilingue (Cardiff NLP) • LangDetect • Aspect Mining
Dashboard Web:	Streamlit 1.32+ con metriche Gold aggregate e filtri reattivi
Sorgenti Supportate:	YouTube Data API v3 (Trailer/Video) • Letterboxd BeautifulSoup Scraper (Recensioni)
Versione Documento:	1.0 (Guida Ufficiale di Riferimento)
Data Rilascio:	November 2026

Indice dei Capitoli

- **Capitolo 1:** Visione Generale & Valore Strategico della Piattaforma
- **Capitolo 2:** Architettura Medallion & Pilastri di Data Governance (Bronze, Silver, Gold)
- **Capitolo 3:** Requisiti di Sistema, Configurazione `.env` & Avvio dei Container
- **Capitolo 4:** Inizializzazione Database, JSON Schema Validation & Indici Idempotenti
- **Capitolo 5:** Pipeline di Ingestione Dati (YouTube Data API v3 & Letterboxd Scraper)
- **Capitolo 6:** Pipeline NLP & Arricchimento Silver (Modelli per lingua, 5 Aspetti Tematici, Sentiment per Aspetto)
- **Capitolo 7:** Guida Operativa alla Dashboard Streamlit & Analitiche Gold
- **Capitolo 8:** Risoluzione dei Problemi, Manutenzione & FAQ Operative

1. Visione Generale & Valore Strategico

Il **Sentiment Analysis & Social Listening Hub** è una piattaforma progettata per intercettare, strutturare ed elaborare le reazioni del pubblico e della critica cinematografica. Nel mercato dell'intrattenimento, il sentiment generato sui canali social in occasione dell'uscita di trailer, teaser o anteprime influisce in maniera determinante sul passaparola e sul box office. Questo sistema fornisce strumenti quantitativi e qualitativi per monitorare in modo oggettivo l'accoglienza di qualsiasi film, serie TV o franchise multimediale.

I punti cardine che contraddistinguono la soluzione includono:

- **Rigore di Data Governance:** conservazione integrale del lineage di provenienza e validazione dello schema al momento della scrittura nel database.
- **Aspect-Based Social Listening:** sentiment calcolato separatamente per ciascuna delle 5 dimensioni verticali dell'opera (Regia, Cast, Colonna Sonora, Visivo/Estetica, Sceneggiatura/Trama).
- **Multi-Sorgente Complementare:** convergenza tra piattaforme ad altissimo coinvolgimento di massa (YouTube) e community specializzate di appassionati e critici (Letterboxd).

2. Architettura Medallion & Data Governance

I dati fluiscono attraverso un'architettura **Medallion** suddivisa in tre livelli logici su MongoDB:

Livello	Collezione / Entità	Descrizione & Scopo	Governance & Integrità
BRONZE (Raw Data)	raw_youtube raw_letterboxd	Ingestione dei dati grezzi così come estratti dalle API o dallo scraping DOM.	• Indice univoco anti-duplicato • Metadati _governance • Flag processed: False
SILVER (Enriched)	silver_data	Dati ripuliti, normalizzati, arricchiti con score sentiment continuo [-1.0, +1.0], label, lingua e aspetti tematici.	• Strict JSON Schema Validation • Indice univoco source_platform + source_id • Indici su aspetti e lingua
GOLD (Analytics)	Pipeline $group & Dashboard Streamlit	Aggregazioni analitiche, KPI sintetici e visualizzazione interattiva dei dati per decision-maker e analisti.	• Query performanti indicizzate • Lettura read-only analitica • Audit trail completo

[GOVERNANCE] I Tre Pilastri della Data Governance

1. **Data Lineage:** ogni documento Silver contiene source_platform, source_id ed extraction_timestamp.
2. **JSON Schema Validation:** MongoDB respinge record privi di sentiment score, testo o label corrette.
3. **Idempotenza:** logiche di upsert prevengono duplicati e mantengono lo stato di elaborazione.

3. Requisiti di Sistema & Avvio dell'Ambiente

Prerequisiti: Linux (Ubuntu consigliato), macOS o Windows WSL2 • Python 3.11+ • Docker 24+ con plugin Compose v2 • 4 GB RAM.

File di Configurazione Ambiente (.env):

```
MONGO_ROOT_PASSWORD=CAMBIA_QUESTA_PASSWORD
MONGO_EXPRESS_PASSWORD=CAMBIA_QUESTA_PASSWORD
MONGODB_URI=mongodb://root:CAMBIA_QUESTA_PASSWORD@localhost:27017/
MONGODB_DB_NAME=sentiment_db
YOUTUBE_API_KEY=INSERISCI_LA_TUA_CHIAVE_API_YOUTUBE
TRANSFORMERS_MODEL_EN=cardiffnlp/twitter-roberta-base-sentiment-latest
TRANSFORMERS_MODEL_MULTI=cardiffnlp/twitter-xlm-roberta-base-sentiment
```

Ogni variabile deve comparire una sola volta: se MONGODB_URI è definita due volte, vale l'ultima riga. Per usare un cluster MongoDB Atlas indicare la sua URI mongodb+srv://; per il database locale in Docker usare localhost con la stessa password di MONGO_ROOT_PASSWORD. Il file .env non viene mai versionato.

Modalità di Esecuzione Disponibili

• **Modalità Docker Completa (Consigliata):** avvia MongoDB, Mongo Express e Dashboard Streamlit:

```
docker compose up -d
```

Per sicurezza MongoDB (27017), Mongo Express (8081) e la dashboard (8501) sono raggiungibili solo da localhost.

• **Modalità Ibrida (Sviluppo Locale):** avvia solo il database in Docker ed esegue gli script in virtualenv. Per la pipeline NLP servono anche PyTorch e Transformers (extra nlp):

```
docker compose up -d mongodb
source venv/bin/activate && pip install -e ".[nlp]"
```

4. Inizializzazione Database, Schema & Indici

Prima di effettuare qualunque ingestione o analisi, è necessario inizializzare il database eseguendo:

```
python -m src.db.init_db
```

Operazioni Eseguite da `init_db.py`

• **Creazione Collezioni Bronze:** inizializza raw_youtube e raw_letterboxd.

• **Schema di Validazione Rigoroso per silver_data:** impone la presenza di original_text, cleaned_text, sentiment_score (double compreso tra -1.0 e 1.0), sentiment_label (Positive, Negative, Neutral) e del blocco _governance completo. Il campo opzionale aspect_sentiments (aspetto, score, label e frase) viene validato elemento per elemento.

• **Creazione Indici Univoci di Idempotenza:**

1. raw_youtube.comment_id (univoco: blocca inserimenti multipli dello stesso commento).

2. raw_letterboxd.film + review_id (univoco: una voce per recensione; lo stesso autore può quindi recensire più volte lo stesso film).

3. silver_data.source_platform + source_id (univoco: garantisce tracciabilità e lineage privo di doppioni).

• **Indici di Performance:** indicizzazione di aspects, language e _governance.processed.

[ATTENZIONE] Regola di Robustezza dello Schema

La validazione schema opera a livello di motore MongoDB. Se un record presenta campi non conformi, viene rigettato con DocumentFailedValidation, preservando la pulizia del layer Silver. Dopo ogni aggiornamento del progetto che modifica lo schema, rieseguire python -m src.db.init_db (è idempotente) prima di elaborare nuovi dati.

5. Pipeline di Ingestione Dati (Bronze Layer)

Il layer Bronze raccoglie i dati esterni preservandoli fedelmente. Include due client pronti all'uso:

5.1 Ingestione YouTube Data API v3 (`src/ingestion/youtube.py`)

Interroga i thread di commenti associati a uno o più video YouTube (trailer ufficiali, teaser, video-recensioni), ordinandoli per rilevanza per massimizzare la qualità del feedback estratto.

Funzionalità e Architettura:

- **Paginazione Automatica:** supporta il superamento del limite dei 100 commenti per pagina tramite pageToken.
- **Campi Estratti:** video_id, video_title, comment_id, author, text, like_count, published_at e metadati _governance.
- **Upsert Idempotente:** aggiorna i metadati esistenti (es. like) senza resettare il flag di elaborazione processed.
- **Campione Multilingue:** l'elenco dei video è in config/youtube_videos.json. Per bilanciare le lingue si possono aggiungere video in italiano (recensioni, reaction, trailer di Prime Video Italia): i commenti ai trailer in inglese sono molto più numerosi.

Esempio di Esecuzione e Codice Python:

```
# Esecuzione da terminale (video elencati in config/youtube_videos.json)
python -m src.ingestion.youtube --max-results 300
# Oppure uno o più video specifici (ripetere --video):
python -m src.ingestion.youtube --video ID_VIDEO --max-results 100

# Utilizzo come modulo per qualsiasi film/video:
from src.ingestion.youtube import get_youtube_comments, save_to_bronze
dati = get_youtube_comments(video_id='XXXXXX', max_results=100, video_title='Trailer 1')
save_to_bronze(dati)
```

5.2 Scraper Letterboxd (`src/ingestion/letterboxd.py`)

Esegue lo scraping etico delle recensioni degli utenti cinefili da Letterboxd utilizzando BeautifulSoup4, adattandosi alla struttura moderna del DOM (article.production-viewing).

Funzionalità e Architettura:

- **Navigazione Pagine:** itera tra le pagine di recensioni ordinate per attività recente.
- **Campi Estratti:** film (slug), author, rating in stelle (es. ★★★★), text e _governance.raw_url.
- **Deduplicazione:** chiave composta film + review_id per garantire unicità della voce.
- **Limite Noto:** Letterboxd può rifiutare le richieste automatiche con 403 Forbidden. In quel caso non si ottengono recensioni: riprovare più tardi o da un'altra rete, senza forzare il blocco.

Esempio di Esecuzione e Codice Python:

```
# Esecuzione da terminale
python -m src.ingestion.letterboxd

# Utilizzo come modulo per qualsiasi film (slug URL):
from src.ingestion.letterboxd import scrape_letterboxd_reviews, save_to_bronze
recensioni = scrape_letterboxd_reviews(film_slug='the-matrix', max_pages=3)
save_to_bronze(recensioni)
```

[NOTA] Come identificare lo slug di Letterboxd

Lo slug è la parte finale dell'indirizzo del film su Letterboxd. Ad esempio per https://letterboxd.com/film/dune-part-two/ lo slug è dune-part-two.

6. Pipeline NLP & Arricchimento (Silver Layer)

Il modulo src/processing/sentiment.py orchestra l'elaborazione NLP. Recupera ciclicamente a batch i record non ancora processati (_governance.processed != True), applica quattro stadi di arricchimento e li salva con upsert nella collezione silver_data:

```
python -m src.processing.sentiment
```

I Quattro Stadi della Pipeline NLP

Stadio	Strumento / Metodo	Dettaglio del Trattamento
1. Data Cleaning	Espressioni Regolari (Regex)	Rimozione di link URL, tag HTML residui, simboli non convenzionali e compressione degli spazi bianchi multipli. Apostrofi, virgolette e trattini tipografici (es. “l’ora”) vengono prima normalizzati, altrimenti le parole si fonderebbero (“lora”) e il modello le leggerebbe male.
2. Language Detection	langdetect	Riconoscimento automatico del codice lingua ISO (es. it, en, es, de) con seed fissato per riproducibilità.
3. Aspect Mining	Pattern Matching bilingue (IT/EN)	Ricerca di keyword tematiche per attribuire ciascun commento a uno o più argomenti del vocabolario cinematografico. Il commento è diviso in frasi e nei connettivi di contrasto (ma, però, but, however): ogni aspetto riceve il sentiment della frase in cui compare. Le parole chiave ambigue (es. “bianco e nero”, “colori”) generano l'aspetto solo se la frase esprime un'opinione.
4. Sentiment Scoring	RoBERTa (EN) XLM-RoBERTa (IT e altre) (Cardiff NLP)	Il modello è scelto in base alla lingua rilevata (inglese: RoBERTa; italiano e altre lingue: XLM-RoBERTa). Inferenza con mappatura su score continuo [-1.0, +1.0] e classificazione in Positive, Neutral, Negative, sia per l'intero commento sia per ogni aspetto.

Tassonomia delle 5 Dimensioni di Aspect-Based Listening

- **directing (Regia):** regia, cineasta, filmmaker, visione registica, ritmo dell'opera.
- **acting (Recitazione / Cast):** interpretazione, attori, cast, performance dei protagonisti.
- **soundtrack (Colonna Sonora / Audio):** colonna sonora, brani musicali, sound design, compositore.
- **visuals (Estetica, Fotografia & CGI):** cinematografia, effetti speciali, estetica, cromie, bianco e nero (queste ultime solo se accompagnate da un giudizio).
- **plot (Trama & Sceneggiatura):** storia, script, dialoghi, sviluppo dei personaggi, finale.

[PIPELINE] Batching Automatico & Audit Trail

La funzione process_unprocessed_data() elabora tutti i documenti Bronze pendenti a blocchi da 100 fino a conclusione. Ciascun record Bronze viene marcato con _governance.processed: True e relativo timestamp UTC di audit.

Riprocessare i Dati Dopo una Modifica

Ogni record Silver registra il modello usato e la versione di pulizia (cleaning_version). Dopo aver cambiato modello, vocabolario degli aspetti o logica di pulizia, incrementare CLEANING_VERSION in sentiment.py e rieseguire, nell'ordine:

```
python -m src.db.init_db

python -m src.processing.sentiment --reprocess-outdated
```

Finché un record non è riprocessato, la dashboard usa per i suoi aspetti il sentiment dell'intero commento.

Limiti noti: un aspetto vale quanto la frase in cui compare; i contrasti senza connettivo (“Regia splendida, colonna sonora noiosa”) e le subordinate non vengono separati; ironia e modi di dire possono essere letti male dai modelli.

7. Guida alla Dashboard Streamlit (Gold Layer)

Il layer Gold rende fruibili le analitiche attraverso un'applicazione web interattiva sviluppata in **Streamlit**. Le metriche non sono precalcolate staticamente, ma vengono aggregate al volo tramite pipeline MongoDB ($match, $group, $avg, $unwind), garantendo reattività immediata ai filtri.

Comando di Avvio

```
streamlit run src/dashboard/app.py

# Accessibile all'URL: http://localhost:8501
```

Struttura & Funzionalità dell'Interfaccia

Modulo Interfaccia	Descrizione & Operatività Utente
KPI Header Cards	**1. Volume Totale:** conteggio dei contributi analizzati. **2. Sentiment Medio:** score continuo aggregato da -1.0 a +1.0. **3. Top Aspect:** l'aspetto più discusso dal pubblico (es. Acting o Visuals).
Sidebar Filtri Reattivi	Filtri combinabili che ricalcolano tutte le viste in tempo reale: • **Piattaforma:** Tutte, solo YouTube, solo Letterboxd. • **Aspetto Tematico:** Tutti o focus su singola dimensione (Directing, Acting, Soundtrack, Visuals, Plot). La ripartizione per lingua è mostrata come tabella, non come filtro.
Visualizzazioni Analitiche	• **Distribuzione Sentiment:** conteggio suddiviso per Positive, Neutral e Negative. • **Gradimento per Aspetto:** confronto dello score medio, e dei commenti positivi e negativi, tra le 5 aree tematiche; ogni valore riguarda la frase in cui l'aspetto è citato. • **Ripartizione Lingue & Canali:** metriche di penetrazione geografica e di canale.
Social Feed Interattivo	Feed cronologico dei commenti completi di badge identificativi: • Origine (YouTube o Letterboxd) • Score normalizzato e classificazione (es. +0.78 Positive) • Lingua e aspetti con il sentiment della propria frase (es. directing (+0.91), soundtrack (-0.74)).

[SUGGERIMENTO] Analisi Mirata delle Dimensioni Critiche

Combinando il filtro 'Aspetto Tematico' (es. soundtrack) con la piattaforma (es. youtube), è possibile isolare immediatamente i commenti specifici per valutare il gradimento delle musiche o del cast.

8. Risoluzione Problemi, Manutenzione & FAQ

D: Errore 'Connection refused' su porta 27017 (MongoDB).

R: Il server MongoDB non è attivo. Avviarlo con docker compose up -d mongodb oppure verificare con docker ps se il container è in stato 'Up'.

D: Errore 'permission denied while trying to connect to the docker API at unix:///var/run/docker.sock'.

R: Su Linux l'utente deve appartenere al gruppo docker. Eseguire sudo usermod -aG docker $USER seguito da newgrp docker (oppure riavviare la sessione). In alternativa, anteporre sudo ai comandi docker.

D: Conflitto di container ('Conflict. The container name is already in use').

R: È presente un container con lo stesso nome da una sessione precedente. Rimuoverlo con docker rm -f sentiment_mongodb e riavviare con docker compose up -d mongodb.

D: Come gestire i limiti di quota di YouTube Data API v3?

R: Google fornisce gratuitamente 10.000 unità al giorno per progetto. Ogni chiamata a commentThreads.list richiede solo 1 unità di quota e preleva fino a 100 commenti. È quindi possibile raccogliere fino a 1.000.000 di commenti al giorno a costo zero.

D: Errore 'Document failed validation' durante l'inserimento in Silver.

R: Il documento non rispetta le regole imposte dallo schema (es. score fuori dal range [-1.0, 1.0] o assenza del lineage di governance). Lo schema protegge l'integrità del database rifiutando il record malformato.

D: Errore 'DNS query name does not exist' (NXDOMAIN) con MongoDB Atlas.

R: Il cluster Atlas è sospeso o eliminato (i cluster gratuiti inattivi vengono messi in pausa). Riattivarlo dalla console Atlas, oppure verificare che MONGODB_URI nel .env sia corretta e definita una sola volta.

D: Perché l'ingestione YouTube dice che la chiave non è configurata?

R: In .env la variabile YOUTUBE_API_KEY è assente o contiene ancora il segnaposto. Creare una chiave dalla Google Cloud Console (API e servizi, YouTube Data API v3) e incollarla nel file.

D: Letterboxd risponde '403 Forbidden' e non scarica recensioni.

R: Il sito rifiuta le richieste automatiche. Riprovare più tardi o da una rete diversa; la pipeline funziona comunque con le sole fonti YouTube.

Best Practice di Manutenzione & Scalabilità

- **Backup del Database:** eseguire dump periodici con docker exec sentiment_mongodb mongodump --out /data/backup.
- **Estensione Vocabolari:** aggiornare config/aspects.yaml per includere nuovi registi, attori o termini specifici del film in esame (le parole ambigue vanno in opinion_only), poi riprocessare i dati come descritto nel capitolo 6.
- **Integrazione Nuove Fonti:** definire nuove collection Bronze (es. raw_imdb) mantenendo il blocco _governance per preservare il lineage.

[DOCUMENTAZIONE] Supporto & Documentazione Tecnica di Progetto

Per dettagli architetturali aggiuntivi, consultare il file README.md nella radice del progetto o la documentazione delle API nel repository ufficiale.