

Sentiment Analysis & Social Listening Hub

Piattaforma Enterprise di Social Listening, Deep Learning NLP e Data Governance per l'Industria Cinematografica e dei Media

Progetto:	Sentiment Analysis & Social Listening Hub
Architettura Dati:	Medallion Architecture (Bronze, Silver, Gold Layers)
Database & Storage:	MongoDB 6.0 con JSON Schema Validation e Indici Idempotenti
Modello NLP:	Twitter-RoBERTa-Base (Cardiff NLP) • LangDetect • Aspect Mining
Dashboard Web:	Streamlit 1.32+ con metriche Gold aggregate e filtri reattivi
Sorgenti Supportate:	YouTube Data API v3 (Trailer/Video) • Letterboxd BeautifulSoup Scraper (Recensioni)
Versione Documento:	1.0 (Guida Ufficiale di Riferimento)
Data Rilascio:	September 2026

Indice dei Capitoli

- Capitolo 1:** Visione Generale & Valore Strategico della Piattaforma
- Capitolo 2:** Architettura Medallion & Pilastri di Data Governance (Bronze, Silver, Gold)
- Capitolo 3:** Requisiti di Sistema, Configurazione `.env` & Avvio dei Container
- Capitolo 4:** Inizializzazione Database, JSON Schema Validation & Indici Idempotenti
- Capitolo 5:** Pipeline di Ingestione Dati (YouTube Data API v3 & Letterboxd Scraper)
- Capitolo 6:** Pipeline NLP & Arricchimento Silver (RoBERTa, 5 Aspetti Tematici, Lingue)
- Capitolo 7:** Guida Operativa alla Dashboard Streamlit & Analitiche Gold
- Capitolo 8:** Risoluzione dei Problemi, Manutenzione & FAQ Operative

1. Visione Generale & Valore Strategico

Il **Sentiment Analysis & Social Listening Hub** è una piattaforma progettata per intercettare, strutturare ed elaborare le reazioni del pubblico e della critica cinematografica. Nel mercato dell'intrattenimento, il sentiment generato sui canali social in occasione dell'uscita di trailer, teaser o anteprime influisce in maniera determinante sul passaparola e sul box office. Questo sistema fornisce strumenti quantitativi e qualitativi per monitorare in modo oggettivo l'accoglienza di qualsiasi film, serie TV o franchise multimediale.

I punti cardine che contraddistinguono la soluzione includono:

- **Rigore di Data Governance:** conservazione integrale del lineage di provenienza e validazione dello schema al momento della scrittura nel database.
- **Aspect-Based Social Listening:** scomposizione del sentiment su 5 dimensioni verticali dell'opera (Regia, Cast, Colonna Sonora, Visivo/Estetica, Sceneggiatura/Trama).
- **Multi-Sorgente Complementare:** convergenza tra piattaforme ad altissimo coinvolgimento di massa (YouTube) e community specializzate di appassionati e critici (Letterboxd).

2. Architettura Medallion & Data Governance

I dati fluiscono attraverso un'architettura **Medallion** suddivisa in tre livelli logici su MongoDB:

Livello	Collezione / Entità	Descrizione & Scopo	Governance & Integrità
BRONZE (Raw Data)	raw_youtube raw_letterboxd	Ingestione dei dati grezzi così come estratti dalle API o dallo scraping DOM.	• Indice univoco anti-duplicato • Metadati _governance • Flag processed: False
SILVER (Enriched)	silver_data	Dati ripuliti, normalizzati, arricchiti con score sentiment continuo [-1.0, +1.0], label, lingua e aspetti tematici.	• Strict JSON Schema Validation • Indice univoco source_platform + source_id • Indici su aspetti e lingua
GOLD (Analytics)	Pipeline \$group & Dashboard Streamlit	Aggregazioni analitiche, KPI sintetici e visualizzazione interattiva dei dati per decision-maker e analisti.	• Query performanti indicizzate • Lettura read-only analitica • Audit trail completo

[GOVERNANCE] I Tre Pilastri della Data Governance

1. **Data Lineage:** ogni documento Silver contiene source_platform, source_id ed extraction_timestamp.
2. **JSON Schema Validation:** MongoDB respinge record privi di sentiment score, testo o label corrette.
3. **Idempotenza:** logiche di upsert prevengono duplicati e mantengono lo stato di elaborazione.

3. Requisiti di Sistema & Avvio dell'Ambiente

Prerequisiti: Linux (Ubuntu consigliato), macOS o Windows WSL2 • Python 3.11+ • Docker 24+ con plugin Compose v2 • 4 GB RAM.

File di Configurazione Ambiente (.env):

```
MONGODB_URI=mongodb://root:example_password@localhost:27017/
MONGODB_DB_NAME=sentiment_db
YOUTUBE_API_KEY=AIzaSyBcsZVJ0ZVJqq-ESEMP10_API_KEY
TRANSFORMERS_MODEL=cardiffnlp/twitter-roberta-base-sentiment-latest
```

Modalità di Esecuzione Disponibili

• **Modalità Docker Completa (Consigliata):** avvia MongoDB, Mongo Express e Dashboard Streamlit:

```
docker compose up -d
```

• **Modalità Ibrida (Sviluppo Locale):** avvia solo il database in Docker ed esegue gli script in virtualenv:

```
docker compose up -d mongodb
source venv/bin/activate && pip install -r requirements.txt
```

4. Inizializzazione Database, Schema & Indici

Prima di effettuare qualunque ingestione o analisi, è necessario inizializzare il database eseguendo:

```
python src/db/init_db.py
```

Operazioni Eseguite da `init\_db.py`

- **Creazione Collezioni Bronze:** inizializza raw_youtube e raw_letterboxd.
- **Schema di Validazione Rigoroso per silver_data:** impone la presenza di original_text, cleaned_text, sentiment_score (double compreso tra -1.0 e 1.0), sentiment_label (Positive, Negative, Neutral) e del blocco _governance completo.
- **Creazione Indici Univoci di Idempotenza:**
 1. raw_youtube.comment_id (univoco: blocca inserimenti multipli dello stesso commento).
 2. raw_letterboxd.film + author (univoco: una sola recensione per autore per film).
 3. silver_data.source_platform + source_id (univoco: garantisce tracciabilità e lineage privo di doppioni).
- **Indici di Performance:** indicizzazione di aspects, language e _governance.processed.

[ATTENZIONE] Regola di Robustezza dello Schema

La validazione schema opera a livello di motore MongoDB. Se un record presenta campi non conformi, viene rigettato con DocumentFailedValidation, preservando la pulizia del layer Silver.

5. Pipeline di Ingestione Dati (Bronze Layer)

Il layer Bronze raccoglie i dati esterni preservandoli fedelmente. Include due client pronti all'uso:

5.1 Ingestione YouTube Data API v3 (`src/ingestion/youtube.py`)

Interroga i thread di commenti associati a uno o più video YouTube (trailer ufficiali, teaser, video-recensioni), ordinandoli per rilevanza per massimizzare la qualità del feedback estratto.

Funzionalità e Architettura:

- **Paginazione Automatica:** supporta il superamento del limite dei 100 commenti per pagina tramite pageToken.
- **Campi Estratti:** video_id, video_title, comment_id, author, text, like_count, published_at e metadati _governance.
- **Upsert Idempotente:** aggiorna i metadati esistenti (es. like) senza resettare il flag di elaborazione processed.

Esempio di Esecuzione e Codice Python:

```
# Esecuzione da terminale
python src/ingestion/youtube.py

# Utilizzo come modulo per qualsiasi film/video:
from src.ingestion.youtube import get_youtube_comments, save_to_bronze
dati = get_youtube_comments(video_id='XXXXXX', max_results=100, video_title='Trailer 1')
save_to_bronze(dati)
```

5.2 Scraper Letterboxd (`src/ingestion/letterboxd.py`)

Esegue lo scraping etico delle recensioni degli utenti cinefili da Letterboxd utilizzando BeautifulSoup4, adattandosi alla struttura moderna del DOM (article.production-viewing).

Funzionalità e Architettura:

- **Navigazione Pagine:** itera tra le pagine di recensioni ordinate per attività recente.
- **Campi Estratti:** film (slug), author, rating in stelle (es. ★★★★★), text e _governance.raw_url.
- **Deduplicazione:** chiave composta film + author per garantire unicità della voce.

Esempio di Esecuzione e Codice Python:

```
# Esecuzione da terminale
python src/ingestion/letterboxd.py

# Utilizzo come modulo per qualsiasi film (slug URL):
from src.ingestion.letterboxd import scrape_letterboxd_reviews, save_to_bronze
recensioni = scrape_letterboxd_reviews(film_slug='the-matrix', max_pages=3)
save_to_bronze(recensioni)
```

[NOTA] Come identificare lo slug di Letterboxd

Lo slug è la parte finale dell'indirizzo del film su Letterboxd. Ad esempio per <https://letterboxd.com/film/dune-part-two/> lo slug è dune-part-two.

6. Pipeline NLP & Arricchimento (Silver Layer)

Il modulo `src/processing/sentiment.py` orchestra l'elaborazione NLP. Recupera ciclicamente a batch i record non ancora processati (`_governance.processed != True`), applica quattro stadi di arricchimento e li salva con `upsert` nella collezione `silver_data`:

```
python src/processing/sentiment.py
```

I Quattro Stadi della Pipeline NLP

Stadio	Strumento / Metodo	Dettaglio del Trattamento
1. Data Cleaning	Espressioni Regolari (Regex)	Rimozione di link URL, tag HTML residui, simboli non convenzionali e compressione degli spazi bianchi multipli.
2. Language Detection	langdetect	Riconoscimento automatico del codice lingua ISO (es. it, en, es, de) con seed fissato per riproducibilità.
3. Aspect Mining	Pattern Matching bilingue (IT/EN)	Ricerca di keyword tematiche per attribuire ciascun commento a uno o più argomenti del vocabolario cinematografico.
4. Sentiment Scoring	Transformer RoBERTa (Cardiff NLP)	Inferenza Deep Learning con mappatura su score continuo [-1.0, +1.0] e classificazione in Positive, Neutral, Negative.

Tassonomia delle 5 Dimensioni di Aspect-Based Listening

- **directing (Regia)**: regia, cineasta, filmmaker, visione registica, ritmo dell'opera.
- **acting (Recitazione / Cast)**: interpretazione, attori, cast, performance dei protagonisti.
- **soundtrack (Colonna Sonora / Audio)**: colonna sonora, brani musicali, sound design, compositore.
- **visuals (Estetica, Fotografia & CGI)**: cinematografia, effetti speciali, estetica, cromie, bianco e nero.
- **plot (Trama & Sceneggiatura)**: storia, script, dialoghi, sviluppo dei personaggi, finale.

[PIPELINE] Batching Automatico & Audit Trail

La funzione `process_unprocessed_data()` elabora tutti i documenti Bronze pendenti a blocchi da 100 fino a conclusione. Ciascun record Bronze viene marcato con `_governance.processed: True` e relativo timestamp UTC di audit.

7. Guida alla Dashboard Streamlit (Gold Layer)

Il layer Gold rende fruibili le analitiche attraverso un'applicazione web interattiva sviluppata in **Streamlit**. Le metriche non sono precalcolate staticamente, ma vengono aggregate al volo tramite pipeline MongoDB (\$match, \$group, \$avg, \$unwind), garantendo reattività immediata ai filtri.

Comando di Avvio

```
streamlit run src/dashboard/app.py  
# Accessibile all'URL: http://localhost:8501
```

Struttura & Funzionalità dell'Interfaccia

Modulo Interfaccia	Descrizione & Operatività Utente
KPI Header Cards	Volume Totale: conteggio dei contributi analizzati. Sentiment Medio: score continuo aggregato da -1.0 a +1.0. Top Aspect: l'aspetto più discusso dal pubblico (es. Acting o Visuals).
Sidebar Filtri Reattivi	Filtri combinabili che ricalcolano tutte le viste in tempo reale: • Piattaforma: Tutte, solo YouTube, solo Letterboxd. • Aspetto Tematico: Tutti o focus su singola dimensione (Directing, Acting, Soundtrack, Visuals, Plot). • Lingua: Selezione per codice ISO (Inglese, Italiano, ecc.).
Visualizzazioni Analitiche	• Distribuzione Sentiment: conteggio suddiviso per Positive, Neutral e Negative. • Gradimento per Aspetto: confronto dello score medio tra le 5 aree tematiche. • Ripartizione Lingue & Canali: metriche di penetrazione geografica e di canale.
Social Feed Interattivo	Feed cronologico dei commenti completi di badge identificativi: • Origine (YouTube o Letterboxd) • Score normalizzato e classificazione (es. +0.78 Positive) • Badge lingua e tag tematici associati.

[SUGGERIMENTO] Analisi Mirata delle Dimensioni Critiche

Combinando il filtro 'Aspetto Tematico' (es. soundtrack) con la piattaforma (es. youtube), è possibile isolare immediatamente i commenti specifici per valutare il gradimento delle musiche o del cast.

8. Risoluzione Problemi, Manutenzione & FAQ

D: Errore 'Connection refused' su porta 27017 (MongoDB).

R: Il server MongoDB non è attivo. Avviarlo con `docker compose up -d mongodb` oppure verificare con `docker ps` se il container è in stato 'Up'.

D: Errore 'permission denied while trying to connect to the docker API at unix:///var/run/docker.sock'.

R: Su Linux l'utente deve appartenere al gruppo docker. Eseguire `sudo usermod -aG docker $USER` seguito da `newgrp docker` (oppure riavviare la sessione). In alternativa, anteporre `sudo` ai comandi docker.

D: Conflitto di container ('Conflict. The container name is already in use').

R: È presente un container con lo stesso nome da una sessione precedente. Rimuoverlo con `docker rm -f sentiment_mongodb` e riavviare con `docker compose up -d mongodb`.

D: Come gestire i limiti di quota di YouTube Data API v3?

R: Google fornisce gratuitamente 10.000 unità al giorno per progetto. Ogni chiamata a `commentThreads.list` richiede solo 1 unità di quota e preleva fino a 100 commenti. È quindi possibile raccogliere fino a 1.000.000 di commenti al giorno a costo zero.

D: Errore 'Document failed validation' durante l'inserimento in Silver.

R: Il documento non rispetta le regole imposte dallo schema (es. score fuori dal range `[-1.0, 1.0]` o assenza del lineage di governance). Lo schema protegge l'integrità del database rifiutando il record malformato.

Best Practice di Manutenzione & Scalabilità

- **Backup del Database:** eseguire dump periodici con `docker exec sentiment_mongodb mongodump --out /data/backup`.
- **Estensione Vocabolari:** aggiornare `ASPECT_KEYWORDS` in `src/processing/sentiment.py` per includere nuovi registi, attori o termini specifici del film in esame.
- **Integrazione Nuove Fonti:** definire nuove collection Bronze (es. `raw_imdb`) mantenendo il blocco `_governance` per preservare il lineage.

[DOCUMENTAZIONE] Supporto & Documentazione Tecnica di Progetto

Per dettagli architetturali aggiuntivi, consultare il file `README.md` nella radice del progetto o la documentazione delle API nel repository ufficiale.